

Éthique de l'IA : biais, transparence et gouvernance



5 août 2026



8 h 30 – 11 h 30



Sherbrooke



STUDIO



En classe : INDIVIDUEL · Remise : INDIVIDUEL



Temps estimé : 150 min (~2.5 h)

OBJECTIF DE LA SÉANCE

Analyser les enjeux éthiques réels de l'IA en entreprise à partir des cas étudiés. Goldman Sachs, Citibank et Pfizer opèrent tous dans des secteurs réglementés — comment construisent-ils la confiance ? Produire un audit éthique simplifié.

Objectifs d'apprentissage

À LA FIN DE CETTE SÉANCE, VOUS SEREZ CAPABLE DE...

1. Identifier les sources de biais dans les systèmes IA réels (données de Goldman Sachs biaisées vers certains marchés, données historiques de Citibank excluant les crises inédites).
2. Évaluer l'impact des biais IA sur les parties prenantes en contexte financier et pharmaceutique.
3. Concevoir un cadre de gouvernance IA incluant transparence, équité et responsabilité, inspiré des pratiques de Pfizer.
4. Produire un audit éthique simplifié d'un système IA réel.

POINTS CLÉS

- 💡 Goldman Sachs Apple Card : l'agent reproduit et amplifie les inégalités historiques des données — sans intention.
- 💡 Pfizer Charlie : la gouvernance 'by design' coûte moins cher à long terme que la correction après scandale.
- 💡 Le biais IA n'est pas un bug — c'est un miroir des inégalités sociétales codées dans les données.
- 💡 Pour certains systèmes, la Loi 25 (Québec) et l'AI Act (UE) imposent transparence, révisabilité et surveillance humaine proportionnelle au risque.
- 💡 Un cadre de gouvernance efficace : audit régulier, comité d'éthique, métriques d'équité, recours, formation continue.
- 💡 Conformité = plancher. La gouvernance éthique va au-delà de ce qui est légalement requis.

IDÉES REÇUES À ÉVITER

- ⚠️ **Le biais IA est causé par des développeurs malveillants**
 - ✓ La plupart des biais IA émergent involontairement, encodés dans les données historiques qui reflètent des inégalités sociales passées. Personne chez Goldman n'a programmé la discrimination de genre — l'agent l'a apprise des données. C'est précisément ce qui rend la prévention difficile : il faut auditer les données et les sorties, pas seulement le code.
- ⚠️ **Une IA transparente = une IA explicable techniquement**
 - ✓ La transparence agentique a deux niveaux : technique (comment le modèle décide) et opérationnelle (qui peut auditer, qui est responsable, comment recourir). Pour les régulateurs et le public, la transparence opérationnelle compte plus que la transparence technique. Goldman a échoué sur les deux niveaux.
- ⚠️ **Conformité réglementaire = comportement éthique**
 - ✓ La conformité est un plancher, pas un plafond. Un système conforme à la Loi 25 peut encore être éthiquement problématique (par exemple discrimination indirecte non mesurée). La gouvernance éthique va au-delà de la conformité : audits proactifs, comité d'éthique, dialogue avec les parties prenantes affectées.

PRIORITÉS DU SOIR

CORE

taxonomie biais agentique

gouvernance by design vs reactive

cadres réglementaires loi25 aiact

distinction conformité éthique

STRETCH

variables proxy et discrimination indirecte

audit continu et métriques équité

PREVIEW

hitl design session 13

feuille route session 14

CAS RÉELS DE LA SÉANCE

Goldman Sachs — Apple Card : allégations de biais de genre et enquête réglementaire (2019–2021)

Décision crédit / agent scoring opaque ayant créé des disparités non anticipées

En 2019, l'Apple Card (émise par Goldman Sachs) a été accusée de discrimination de genre : des couples mariés recevaient des limites de crédit radicalement différentes entre homme et femme, malgré des finances partagées. L'agent IA avait appris des données historiques de crédit où les femmes avaient statistiquement des limites plus basses. Enquête du New York Department of Financial Services. Conclusion du NY-DFS (mars 2021) : pas de preuve de discrimination illégale établie, mais opacité algorithmique jugée problématique et risque de biais indirect identifié. Coût réputationnel énorme malgré l'absence de sanction légale.

Pfizer — Gouvernance 'by design' de Charlie

Gouvernance / agent classificateur encadré dès la conception (revue humaine, audit trail)

Pfizer a intégré une gouvernance stricte dans Charlie dès la conception : catégorisation par niveau de risque, revue humaine obligatoire pour le contenu médical à risque élevé, audit trail complet, comité d'éthique IA dédié. C'est un exemple de gouvernance 'by design' dans un secteur où une erreur peut affecter la santé publique. Coût ex ante plus élevé, mais évite les coûts ex post (scandale, sanction).

QUESTIONS D'ANALYSE

1. L'agent de Goldman Sachs pour l'Apple Card a discriminé les femmes. Comment un algorithme peut-il être discriminatoire sans que les développeurs l'aient programmé ?
2. Pfizer a intégré la gouvernance dans Charlie dès la conception. Goldman Sachs a découvert le biais après le déploiement. Quelle approche est la plus coûteuse à long terme ?
3. Si vous étiez le Chief Ethics Officer de Goldman Sachs, quelles mesures preniez-vous le lendemain du scandale Apple Card ?
4. La Loi 25 (Québec) s'appliquerait-elle à un système comme Charlie ? Et l'AI Act européen ? Comment ?

LIVRABLE DE SÉANCE

Audit éthique simplifié

Grille d'audit (1.5 pages)

Choisir Goldman Sachs (Apple Card) ou Pfizer (Charlie), ou un agent issu d'un milestone précédent. Remplir la grille : (1) Description du système agentique, (2) Sources de biais potentielles (données, modèle, déploiement), (3) Parties prenantes affectées, (4) Mécanismes de détection en place ou absents, (5) Cadre de gouvernance recommandé (5 points), (6) Conformité Loi 25 / AI Act / OCDE.

- ☐ Sources de biais identifiées avec données réelles ou plausibles
- ☐ Parties prenantes cartographiées avec impact différentiel
- ☐ Mécanismes de détection évalués (existants ou manquants)
- ☐ Cadre de gouvernance en 5 points opérationnels
- ☐ Référence à au moins 1 cadre réglementaire (Loi 25, AI Act, OCDE)
- ☐ Distinction biais ex ante (données) vs ex post (déploiement)
- ☐ Divulgateur IA si applicable

Préparation directe à l'Analyse de cas finale (S15, 25 % du cours)

Pont novice

Premier emploi

⌚ 5 min

SCÉNARIO

Une startup RH utilise une IA pour trier les CV. Les 10 premiers candidats retenus viennent tous des mêmes 3 universités. Personne n'a programmé ça. D'où ça vient ? Qui est responsable ?

CONNEXION AVEC LE CAS ENTREPRISE

Apple Card 2019 : Goldman Sachs n'a pas programmé la discrimination de genre — l'agent l'a apprise des données historiques qui reflétaient des inégalités passées. Le biais s'hérite des données. La gouvernance 'by design' (Pfizer) coûte moins cher que la correction après scandale.

Déroulement de la séance

RYTHME DE LA SOIRÉE

STRUCTURE DE LA SÉANCE

Partie	Titre	Durée	Contenu
1	Apple Card : allégations, enquête NY-DFS et leçons de gouvernance	50 MIN	Wooclap d'ouverture sur la responsabilité. Décortiquer le scandale Apple Card 2019 : chronologie, sources possibles du biais (données historiques, variables proxy), réaction du régulateur NY-DFS, coûts pour Goldman et Apple. Taxonomie des biais agentiques : biais des données, biais de conception, biais de déploiement, biais d'interprétation.
2	Pfizer : gouvernance by design	50 MIN	Comment Charlie intègre l'éthique dès la conception : catégorisation par risque, revue humaine obligatoire à seuil, audit trail, comité d'éthique IA. Cadres réglementaires pertinents : Loi 25 (Québec, transparence et révisabilité pour décisions exclusivement automatisées), AI Act (UE, surveillance humaine proportionnelle au risque), Principes OCDE. Contraste Goldman vs Pfizer : prévention coûteuse vs réaction très coûteuse.
3	Pause	10 MIN	Pause. Distribuer la grille d'audit éthique pour préparer l'exercice.
4	Exercice : audit éthique	40 MIN	Individuel : remplir la grille d'audit pour Goldman, Pfizer, ou un agent du milestone M7/M8/M9. Partage en paires (5 min chacun) avec critique sur : sources de biais plausibles ? Cadre de gouvernance opérationnel ? Référence réglementaire correcte ? 2-3 partages au groupe.

OBJECTIF

Produire un audit éthique simplifié d'un agent (Goldman, Pfizer, ou agent personnel) avec sources de biais, parties prenantes, gouvernance recommandée et référence réglementaire opérationnelle.

LIVRABLE ATTENDU

Grille d'audit éthique (1.5 page)

ARTÉFACTS DU REPO

- ☐ portfolio/M5_audit_ethique.pdf
- ☐ ai-usage.md

CHECKLIST DE REMISE

- ☐ Sources de biais identifiées avec données réelles ou plausibles
- ☐ Parties prenantes cartographiées avec impact différentiel
- ☐ Mécanismes de détection évalués (existants ou manquants)
- ☐ Cadre de gouvernance en 5 points opérationnels
- ☐ Référence à au moins 1 cadre réglementaire (Loi 25, AI Act, OCDE)
- ☐ Distinction biais ex ante (données) vs ex post (déploiement)
- ☐ Divulgateion IA si applicable

Exemples de travaux annotés

Livrable : Grille d'audit éthique simplifié (1.5 page)

✓ EXEMPLE FORT

Système audité : Agent de tri des CV — Startup RH TalentFlow
Date : Avril 2026 | Auditeur : Équipe 3

SECTION 1 — BIAIS ALGORITHMIQUE

Constat : 87 % des candidats retenus proviennent de 4 universités (McGill, UdeM, HEC, Concordia). La population québécoise active représente 23 universités.
Cause identifiée : Données d'entraînement = profils des 50 employés actuels.
Biais d'homophilie confirmé. Pas d'audit externe avant déploiement.
Recommandation : Ré-entraînement avec contrainte de diversité géographique + quotas de représentation par région. Revue humaine systématique pour les candidats hors Top-4 ayant un score > 70 %.

SECTION 2 — TRANSPARENCE

Constat : Les candidats rejetés ne reçoivent aucune explication.
Recommandation : Notification automatique avec 3 critères généraux de rejet.
Conforme à l'article 12 de la Loi 25 (droit à l'explication).

SECTION 3 — RESPONSABILITÉ

Question : Qui est responsable si un biais est détecté post-déploiement ?
Réponse actuelle : Non défini.
Recommandation : Nommer un responsable IA (role owner) dans les 30 jours.

- ✓ Biais quantifié (87 % / 4 universités / 23 disponibles) — auditable et défendable
- ✓ Cause identifiée (biais d'homophilie) — distingue symptôme et cause
- ✓ Recommandations liées à une loi spécifique (Loi 25 art. 12) — crédibilité légale
- ✓ Responsabilité nommée avec deadline (30 jours) — pas juste un constat

✗ EXEMPLE À ÉVITER

Audit éthique de l'agent IA de recrutement

L'agent IA pourrait avoir des biais. Il faut s'assurer qu'il est juste et transparent. Les candidats doivent être traités équitablement. Il faudrait vérifier les données et former les employés sur l'éthique de l'IA.

Globalement, l'utilisation de l'IA en recrutement est acceptable si elle est bien encadrée.

- ✗ 'Pourrait avoir des biais' — aucune analyse, aucune donnée, aucun constat spécifique
- ✗ 'Juste et transparent' — par rapport à quels critères ? Quelle loi ? Quel standard sectoriel ?
- ✗ 'Former les employés' — formation sur quoi ? Durée ? Qui anime ? Quand ?
- ✗ Conclusion 'acceptable si bien encadrée' — l'audit est censé définir précisément ce cadre, pas l'esquiver

Remise & évaluation

ARTÉFACTS REQUIS

☐ portfolio/M10_audit_ethique.pdf

☐ ai-usage.md

RÈGLE DE REMISE



Avant la séance 13 (12 août 2026)

CRITÈRES D'ÉVALUATION

%	Dimension	Accent de la séance
25%	Sources biais identifiées	Sources plausibles dans les données, le modèle ou le déploiement.
15%	Parties prenantes cartographiées	Impact différentiel sur chaque partie prenante explicité.
25%	Gouvernance opérationnelle	5 points opérationnels (pas de vœux pieux).
15%	Reference réglementaire	Au moins 1 cadre réglementaire correctement référencé.
10%	Distinction ex ante ex post	Distinction entre biais ex ante (données) et ex post (déploiement).
5%	Lisibilité	Grille lisible, pas un mur de texte.
5%	Ai disclosure	ai-usage.md présent.

EXIT TICKET



En une phrase : pour votre futur métier, identifiez UN biais potentiel d'un agent IA et UN mécanisme de gouvernance que vous mettriez en place pour le détecter.

DIVULGATION IA — AI-USAGE.MD

1

Outil utilisé

Nom, version, date d'accès

2

Ce qu'il m'a aidé à faire

Tâche précise — pas « écrire le travail »

3

Sources et chiffres vérifiés

Chaque affirmation → source primaire consultée

4

Ce que j'ai modifié ou rejeté

Corrections, reformulations, refus — et pourquoi

5

Déclaration de responsabilité

Je suis responsable de l'exactitude et du jugement — outil IA utilisé ou non.

Présent même si aucun outil IA utilisé · gabarit : [content/templates/ai-usage.md](#)

Vos outils & règles IA pour cette séance

Voici comment vous travaillez ce soir : ce qui est permis, ce qui doit être tracé, et la boîte à outils gratuite à votre disposition.

POLITIQUE IA

IA PERMISE

Les outils IA sont permis lorsqu'explicitement indiqué. Toute utilisation doit être divulguée dans `ai-usage.md`. L'étudiant demeure responsable de l'exactitude, du jugement et de la vérification.

VOS OUTILS INDISPENSABLES

chatgpt or copilot

google docs

slides

canva

POLITIQUE CLOUD

AUCUNE CARTE REQUISE

Voie par défaut: analytics

POUR VOUS, CONCRÈTEMENT

- Acceptez l'invitation GitHub Classroom avant S1.
- Chaque séance : déposez votre PDF dans `<code>portfolio/</code>` avant de partir.
- Remplissez `<code>ai-usage.md</code>` via l'éditeur GitHub web.
- Remplissez l'exit ticket avant 22 h.

Lectures recommandées



NY-DFS Report on Apple Card Investigation (2021)

Le rapport officiel sur l'enquête Apple Card.

<https://www.dfs.ny.gov/>



EU AI Act— Final Text (2024)

Le texte de référence sur la régulation européenne IA.

<https://artificialintelligenceact.eu/>



Loi 25 Québec — Décisions automatisées

Encadrement québécois des décisions automatisées.

<https://www.cai.gouv.qc.ca/>



OECD Principles on AI

Cadre international de référence sur l'IA responsable.

<https://oecd.ai/en/ai-principles>

Exit ticket

Répondez à la question ci-dessous **avant 22 h ce soir**. Votre réponse est individuelle et compte dans votre participation.

QUESTION DE RÉFLEXION

En une phrase : pour votre futur métier, identifiez UN biais potentiel d'un agent IA et UN mécanisme de gouvernance que vous mettriez en place pour le détecter.

COMMENT RÉPONDRE

1. Sortez votre téléphone.
2. Scannez le code QR ou tapez l'adresse ci-dessous.
3. Connectez-vous avec votre courriel UdeS.
4. Rédigez votre réponse et cliquez *Soumettre*.

<https://profos-dhowwtjefa-nn.a.run.app/exit-ticket/GTA651-12>

