

# Humain dans la boucle : conformité et confiance

 12 août 2026

 8 h 30 – 11 h 30

 Sherbrooke

 En classe : **INDIVIDUEL** · Remise : **INDIVIDUEL**

 Temps estimé : 150 min (~2.5 h)

### OBJECTIF DE LA SÉANCE

Comprendre les systèmes HITL en comparant Goldman Sachs (humain décide, IA recommande), Pfizer Charlie (revue humaine obligatoire) et Brex (IA semi-autonome). Identifier le risque d'automation bias. Produire un design d'interface HITL.

## Objectifs d'apprentissage

### À LA FIN DE CETTE SÉANCE, VOUS SEREZ CAPABLE DE...

1. Classer Goldman Sachs (HITL), Brex (HOTL) et un véhicule autonome NVIDIA (HOOTL) selon les trois architectures de supervision.
2. Identifier le risque d'automation bias en contexte réel (ex. : que se passe-t-il si les analystes de Goldman cessent de vérifier les recommandations IA ?).
3. Concevoir une interface HITL qui force la vérification humaine réelle, inspirée de la gouvernance de Pfizer Charlie.
4. Produire un design d'interface HITL avec mécanismes anti-automation-bias.

### POINTS CLÉS

- 💡 Goldman = HITL strict. Brex = HOTL. Pfizer = HITL maximaliste (même pour faible risque).
- 💡 L'automation bias est le danger #1 des systèmes HITL : l'humain cesse de vérifier après exposition prolongée.
- 💡 Pfizer sacrifie de l'efficacité pour de la sécurité — choix de gouvernance, pas d'UX.
- 💡 Le design de l'interface détermine si le HITL est réel ou cosmétique.
- 💡 Un HITL mal designé peut être plus dangereux qu'un HOTL bien designé (fausse impression de contrôle).
- 💡 L'audit du superviseur humain (taux d'approbation, temps de revue) est un mécanisme anti-bias essentiel.

### IDÉES REÇUES À ÉVITER

- ⚠️ **HITL = humain valide tout, donc c'est sûr**
  - ✓ Un HITL mal conçu est une illusion de sécurité. Si l'interface ne force pas la vérification réelle (juste un bouton 'approuver'), les humains tombent rapidement dans l'automation bias. Un HITL réel inclut : information contextuelle, mécanismes anti-bias, audit du superviseur, rotation. Sans ces composants, le HITL est cosmétique.
- ⚠️ **L'automation bias est le problème des utilisateurs, pas du système**
  - ✓ L'automation bias est prévisible et systémique. Tous les humains y sont sujets après exposition prolongée. C'est une responsabilité de design, pas d'utilisateur. Les bons systèmes intègrent des mécanismes pour le contrer : tests injectés, métriques de vigilance, rotation des reviewers.
- ⚠️ **Plus l'humain a de pouvoir d'intervention, mieux c'est**
  - ✓ Trop d'options paralysent. Un HOTL où l'humain peut intervenir 'à tout moment sur n'importe quelle décision' est ingérable. Le bon design définit clairement QUAND l'intervention humaine est attendue, et automatise tout le reste. Le pouvoir d'intervention sans déclencheurs clairs = pas d'intervention.

### PRIORITÉS DU SOIR

#### CORE

hitl hotl hootl revue appliquee

automation bias mecanismes de protection

audit du superviseur humain

design force la verification reelle

#### STRETCH

lecons aviation transposees

calibration seuils intervention

#### PREVIEW

feuille route session 14

examen final session 15

## Cas et livrable

### CAS RÉELS DE LA SÉANCE

#### Goldman Sachs — HITL strict en finance d'investissement

Recommandation / agent dont chaque sortie passe par un analyste humain

Chez Goldman Sachs, l'agent IA produit des recommandations d'investissement mais l'analyste DOIT valider avant toute action. Risque émergent : après des mois d'utilisation, les analystes pourraient commencer à approuver les recommandations sans les vérifier — c'est l'automation bias. Comment Goldman s'en protège-t-il ? Par rotation, par injection de cas tests, par audit des taux d'approbation.

#### Pfizer Charlie — Revue humaine universelle (HITL maximaliste)

Classification / agent dont TOUTES les sorties passent par revue humaine, même 'faible risque'

Charlie catégorise le contenu par risque. Le contenu 'faible risque' pourrait théoriquement être publié sans revue humaine. Pfizer a choisi de maintenir la revue humaine pour TOUT le contenu médical. C'est un choix de gouvernance qui sacrifie de l'efficacité pour de la sécurité — justifié par l'asymétrie extrême des coûts d'erreur en pharma.

#### Brex — HOTL semi-autonome avec escalade conditionnelle

Opérations / agent semi-autonome qui agit, l'humain peut intervenir sur exception

Le CFO virtuel de Brex agit de façon semi-autonome : il catégorise les dépenses et alerte sur les anomalies sans attendre l'approbation humaine. L'humain est 'on the loop' — il peut intervenir mais n'est pas requis pour chaque action. Pour une PME sans CFO, c'est la bonne architecture. Pour Goldman Sachs, ce serait inacceptable. Brex se protège de l'automation bias en limitant le champ d'action autonome aux décisions à faible enjeu.

### QUESTIONS D'ANALYSE

1. Un analyste de Goldman Sachs approuve 95 % des recommandations IA sans modification. Est-ce un signe de confiance justifiée ou d'automation bias ? Comment distinguer ?
2. Pfizer maintient la revue humaine même pour le contenu 'faible risque'. Ce choix est-il irrationnel ou stratégique ?
3. Si Brex passait d'une architecture HOTL à HOOTL (agent totalement autonome pour les décisions budgétaires), quels risques émergeraient ?
4. Comment concevoir une interface qui force l'analyste de Goldman à vraiment lire la recommandation IA avant d'approuver ?

### LIVRABLE DE SÉANCE

#### Choix HITL/HOTL/HOOTL pour un cas sensible

1 paragraphe (texte ou PDF, ½ page max)

Choisissez un cas d'usage sensible (santé, finance, RH, justice). Indiquez HITL, HOTL ou HOOTL et justifiez votre choix en 1 paragraphe.

- ☐ Cas d'usage sensible identifié
- ☐ Architecture choisie (HITL/HOTL/HOOTL)
- ☐ Justification en 1 paragraphe

Contexte campus

⌚ 5 min

### SCÉNARIO

Vous êtes trésorier d'une association étudiante. L'IA a approuvé 15 dépenses pendant votre absence. Vous les avez signées sans les lire. Une erreur de 400 \$ apparaît. Qui est responsable ?

### CONNEXION AVEC LE CAS ENTREPRISE

L'automation bias : le HITL (humain dans la boucle) devient un tampon en caoutchouc après exposition prolongée. Pfizer a conçu des mécanismes structurels qui forcent la vérification réelle. La responsabilité ne disparaît pas parce que l'IA a 'décidé' — elle se déplace vers le designer du système.

## Déroulement de la séance

### RYTHME DE LA SOIRÉE

### STRUCTURE DE LA SÉANCE

| Partie | Titre                               | Durée  | Contenu                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
|--------|-------------------------------------|--------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1      | Trois architectures, trois réalités | 50 MIN | Rappel explicite de S08 (5 min) : 'En S08, vous avez conçu des pipelines HITL/HOTL/HOOTL — entrées, seuils, escalade, feedback. Aujourd'hui on revient sur le même cadre pour répondre à une question différente : pourquoi ces pipelines s'effondrent-ils humainement avec le temps ?' Le concept d'automation bias : le risque invisible qui fait dégrader le HITL après des semaines d'usage. Goldman (HITL), Brex (HOTL), véhicule autonome NVIDIA (HOOTL). Quand chaque architecture est requise ou recommandée. Pourquoi un HITL mal designé peut être pire qu'un HOTL bien designé — la fausse impression de contrôle. |
| 2      | Concevoir un HITL qui fonctionne    | 50 MIN | Cas Pfizer : forcer la revue réelle. Mécanismes anti-automation-bias : tests injectés, rotation des reviewers, métriques de vigilance, ralentissement intentionnel sur cas critiques, justification écrite obligatoire. Audit du superviseur humain (taux d'approbation, temps moyen de revue). Le contre-paradoxe : parfois ralentir l'humain améliore la sécurité globale.                                                                                                                                                                                                                                                  |
| 3      | Pause                               | 10 MIN | Pause. Distribuer le canevas wireframe HITL.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
| 4      | Exercice : votre design HITL        | 40 MIN | Individuel : dessiner le wireframe annoté pour Goldman, Pfizer, Brex ou un agent du milestone M3-M5. Partage en paires (5 min chacun) avec critique sur : le mécanisme anti-bias est-il robuste ? Que se passe-t-il après 6 mois d'usage ? 2-3 partages au groupe.                                                                                                                                                                                                                                                                                                                                                            |

## OBJECTIF

Appliquer les concepts de supervision humaine à un cas sensible.

## LIVRABLE ATTENDU

1 paragraphe (texte ou PDF, ½ page max)

## ARTÉFACTS DU REPO

☐ portfolio/L13\_choix\_hitl.pdf

## Vos outils & règles IA pour cette séance

Voici comment vous travaillez ce soir : ce qui est permis, ce qui doit être tracé, et la boîte à outils gratuite à votre disposition.

### POLITIQUE IA

#### IA PERMISE

Les outils IA sont permis lorsqu'explicitement indiqué. Toute utilisation doit être divulguée dans `ai-usage.md`. L'étudiant demeure responsable de l'exactitude, du jugement et de la vérification.

### VOS OUTILS INDISPENSABLES

chatgpt or copilot

google docs

slides

canva

### POLITIQUE CLOUD

#### AUCUNE CARTE REQUISE

Voie par défaut: analytics

#### POUR VOUS, CONCRÈTEMENT

- Acceptez l'invitation GitHub Classroom avant S1.
- Chaque séance : déposez votre PDF dans `<code>portfolio/</code>` avant de partir.
- Remplissez `<code>ai-usage.md</code>` via l'éditeur GitHub web.
- Remplissez l'exit ticket avant 22 h.

## Lectures recommandées

---



### Parasuraman & Manzey — Complacency and Bias in Human Use of Automation (2010)

La référence académique sur l'automation bias.

<https://journals.sagepub.com/doi/10.1177/0018720810376055>



### Goldman Sachs Engineering Blog (HITL practices)

Insights publics sur les architectures HITL chez Goldman.

<https://developer.gs.com/>



### Pfizer Digital Engineering — Charlie governance

Insights sur la revue humaine universelle chez Pfizer.

<https://www.pfizer.com/news>



### FAA — Automation in Cockpits (lessons for HITL design)

Leçons aviation transposables au HITL en entreprise.

<https://www.faa.gov/>



## Exit ticket

---

Répondez à la question ci-dessous **avant 22 h ce soir**. Votre réponse est individuelle et compte dans votre participation.

### QUESTION DE RÉFLEXION

**En une phrase : pour votre futur métier, identifiez UN mécanisme anti-automation-bias que vous mettriez en place pour vous-même quand vous travaillez avec un agent IA.**

### COMMENT RÉPONDRE

1. Sortez votre téléphone.
2. Scannez le code QR ou tapez l'adresse ci-dessous.
3. Connectez-vous avec votre courriel UdeS.
4. Rédigez votre réponse et cliquez *Soumettre*.

<https://profos-dhowwtjefa-nn.a.run.app/exit-ticket/GTA651-13>

